

L'épidémie de choléra à Londres en 1854

Sébastien Guyader

29 octobre 2018

Introduction

En 1854, le quartier de Soho à Londres a vécu une des pires épidémies de choléra du Royaume-Uni, avec 616 morts. Cette épidémie est devenue célèbre à cause de l'analyse détaillée de ses causes réalisée par le médecin John Snow. Ce dernier a notamment montré que le choléra est transmis par l'eau plutôt que par l'air, ce qui était la théorie dominante de l'époque.

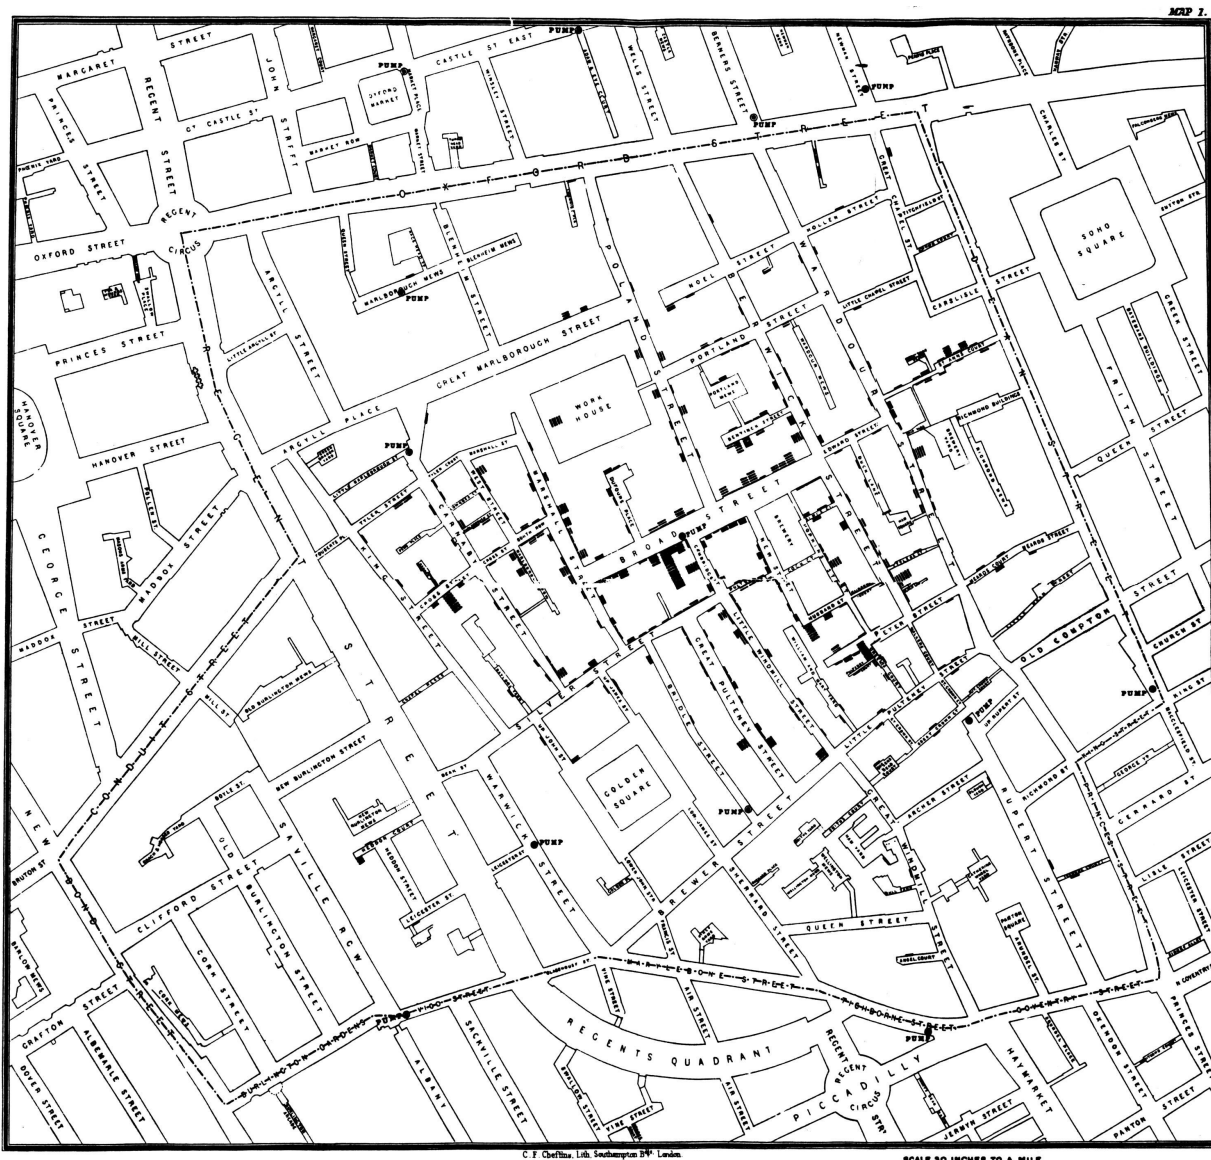
Un élément clé de cette analyse était une carte sur laquelle John Snow avait marqué les lieux des décès et les endroits où se trouvaient les pompes à eau publiques. Ces données sont aujourd'hui disponibles sous forme numérique.

Dans ce document, je vais reproduire une carte similaire à celle de John Snow représenter la carte de Londres

La carte de John Snow

Je propose tout d'abord de visualiser la carte originale (ou une de ses versions) de John Snow pour voir ce vers quoi nous devons tendre :

```
img_url = "https://upload.wikimedia.org/wikipedia/commons/2/27/Snow-cholera-map-1.jpg"
img_file = "Snow-cholera-map-1.jpg"
if (!file.exists(img_file)) {
  download.file(img_url, img_file, method="auto")
}
knitr::include_graphics(img_file)
```



Carte originale de Snow (source Wikimedia Commons)

Générer un fond de carte actuel de la même zone

Le paquet `ggmap` peut être utilisé pour télécharger la carte à partir de différentes API telles que `Google maps` et `OpenStreetMap`. En revanche, il devient difficile d'obtenir des tuiles à partir de ces deux sources à cause de limitations techniques (nécessité d'une clé pour `Google maps`, et limitations du serveur de tuiles `OpenStreetMap`). Le serveur de tuiles `Stamen` semble présenter moins soucis pour le téléchargement de la carte :

```
library(ggmap)
```

```
# définissons les coordonnées de la zone à télécharger
```

```
bbox <- c(left = -0.1433, bottom = 51.5094, right = -0.1286, top = 51.5164)
```

```
# Téléchargeons la carte à partir du serveur Stamen, et utilisons le type "toner-lite" pour une visuali
js_map <- get_stamenmap(bbox = bbox, zoom = 16, maptype = "toner-lite", crop = TRUE, messaging = FALSE,
```

```
# Déterminer la classe de l'objet
class(js_map)
```

```
## [1] "ggmap" "raster"
```

Pour visualiser l'objet obtenu, on utilise la fonction `ggmap` qui transforme l'objet en classe `ggplot` pour une visualisation avec les outils `ggplot2` :

```
js_fond <- ggmap(js_map)
```

```
# Visualisation de la carte
js_fond
```



Obtenir les localisations des pompes à eau et des cas de décès dus au choléra

Téléchargeons les données pour obtenir les fichiers avec les coordonnées au format `shp`. On obtient un fichier zip qu'il faut ensuite décompresser :

```
data_url = "http://rtwilson.com/downloads/SnowGIS_SHP.zip"
data_file = "SnowGIS_SHP.zip"
if (!file.exists(data_file)) {
  download.file(data_url, data_file, method="auto")
}
unzip(data_file)
```

Les fichiers sont localisés dans le répertoire `./SnowGIS_SHP`. Les fichiers portant l'extension `.shp` sont directement lus par la librairie `rgdal` :

```

library(rgdal)
deces <- rgdal::readOGR("./SnowGIS_SHP/Cholera_Deaths.shp")

## OGR data source with driver: ESRI Shapefile
## Source: "/home/sguyader/TRAVAIL/Formations/mooc-rr/module3/exo3/SnowGIS_SHP/Cholera_Deaths.shp", layer: 
## with 250 features
## It has 2 fields

# On observe la structure de l'objet :
summary(deces)

## Object of class SpatialPointsDataFrame
## Coordinates:
##           min      max
## coords.x1 529160.3 529655.9
## coords.x2 180857.9 181306.2
## Is projected: TRUE
## proj4string :
## [+proj=tmerc +lat_0=49 +lon_0=-2 +k=0.9996012717 +x_0=400000
## +y_0=-100000 +ellps=airy +units=m +no_defs]
## Number of points: 250
## Data attributes:
##           Id      Count
## Min.      :0      Min.   : 1.000
## 1st Qu.:0      1st Qu.: 1.000
## Median :0      Median : 1.000
## Mean    :0      Mean   : 1.956
## 3rd Qu.:0      3rd Qu.: 2.000
## Max.    :0      Max.   :15.000

```

Gestion du système de géoréférencement et transformation des coordonnées

Selon les indications de l'auteur du blog fournissant les données, les points ont été géoréférencés dans le système "Ordnance Survey co-ordinate system", appelé "OSGB36 National Grid" (code international EPSG 27700). Cela implique de convertir les coordonnées dans le même système que celui utilisé par Google Maps (WGS84, pour "World Geodetic System 1984") :

```

# convertir l'objet en data frame
deces_df <- as.data.frame(deces)

# donner l'attribut "coordonnées" aux colonnes correspondantes
coordinates(deces_df) <- ~coords.x1+coords.x2

# donne l'attribut du système d'origine de coordonnées projetées selon son code EPSG
proj4string(deces_df) <- CRS("+init=epsg:27700")

# transforme les coordonnées dans le système WGS84 utilisé par Google Maps
deces_df <- as.data.frame(spTransform(deces_df, CRS("+proj=longlat +datum=WGS84")))
coordinates(deces_df) <- ~coords.x1+coords.x2

# on inspecte la structure de l'objet :
summary(deces_df)

## Object of class SpatialPointsDataFrame
## Coordinates:

```

```
##               min           max
## coords.x1 -0.1400738 -0.1329335
## coords.x2 51.5118557 51.5158345
## Is projected: NA
## proj4string : [NA]
## Number of points: 250
## Data attributes:
##      Id      Count
## Min.   :0      Min.   : 1.000
## 1st Qu.:0      1st Qu.: 1.000
## Median :0      Median : 1.000
## Mean   :0      Mean   : 1.956
## 3rd Qu.:0      3rd Qu.: 2.000
## Max.   :0      Max.   :15.000
```

Les coordonnées sont dorénavant dans le bon système.

Maintenant, importons les positions des pompes à eau, en appliquant les mêmes transformations que pour les décès :

```
pompes <- rgdal::readOGR("./SnowGIS_SHP/Pumps.shp")
```

```
## OGR data source with driver: ESRI Shapefile
## Source: "/home/sguyader/TRAVAIL/Formations/mooc-rr/module3/exo3/SnowGIS_SHP/Pumps.shp", layer: "Pumps"
## with 8 features
## It has 1 fields
```

```
pompes_df <- as.data.frame(pompes)
coordinates(pompes_df) <- ~coords.x1+coords.x2
proj4string(pompes_df) <- CRS("+init=epsg:27700")
pompes_df <- as.data.frame(spTransform(pompes_df, CRS("+proj=longlat +datum=WGS84")))
coordinates(pompes_df) <- ~coords.x1+coords.x2
```

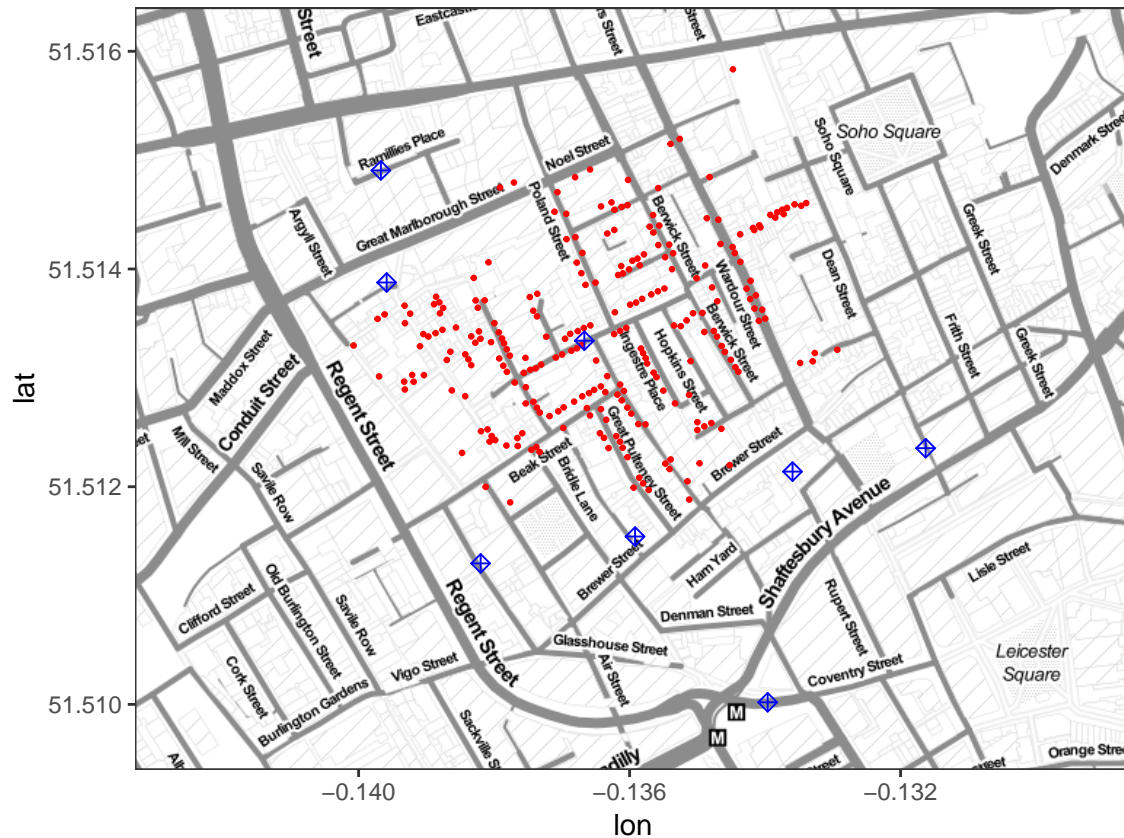
```
# inspectons le data frame
summary(pompes_df)
```

```
## Object of class SpatialPointsDataFrame
## Coordinates:
##               min           max
## coords.x1 -0.139671 -0.1316299
## coords.x2 51.510019 51.5149056
## Is projected: NA
## proj4string : [NA]
## Number of points: 8
## Data attributes:
##      Id
## Min.   :0
## 1st Qu.:0
## Median :0
## Mean   :0
## 3rd Qu.:0
## Max.   :0
```

Projection des points sur le fond de carte

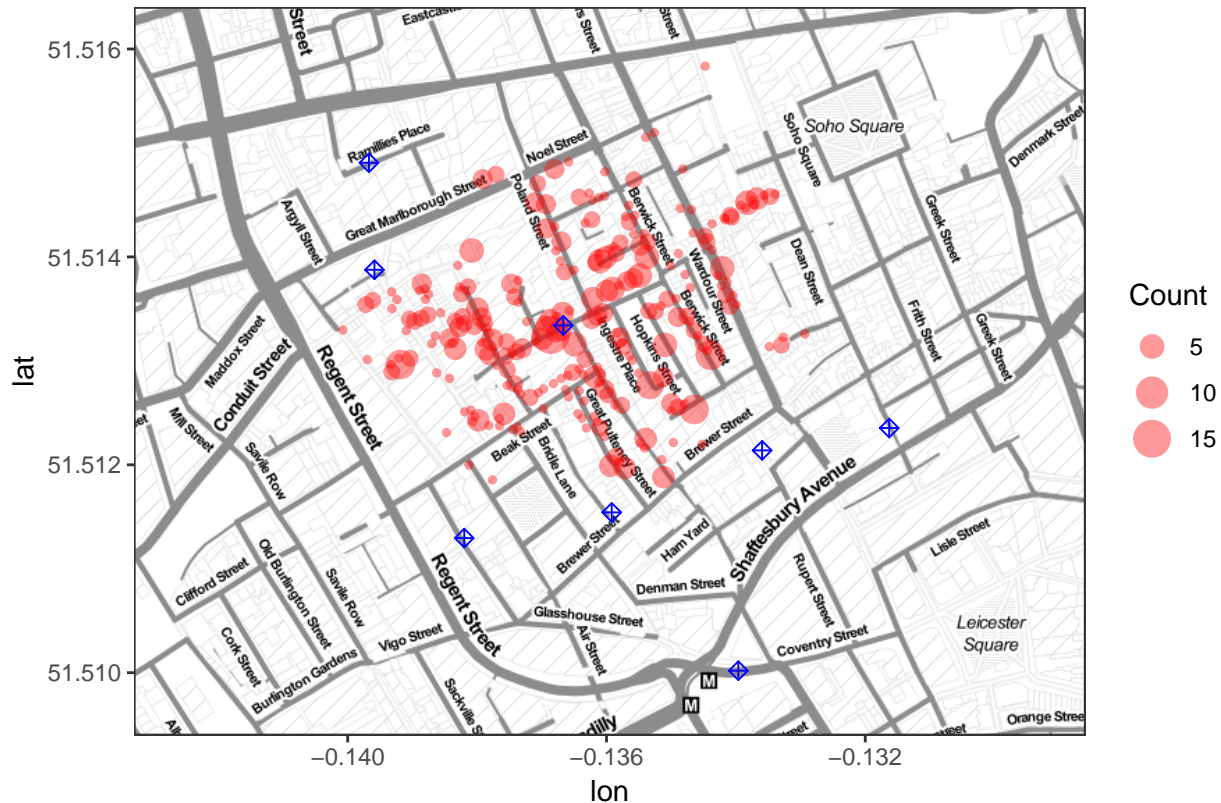
On peut maintenant ajouter les localisations des décès et des pompes sur le fond de carte avec `ggplot2` :


```
js_fond +
  # localisations des décès
  geom_point(data=data.frame(deces_df), aes(x=coords.x1, y=coords.x2),
            col="red", size=0.5) +
  # localisations des pompes
  geom_point(data=data.frame(pompes_df), aes(x=coords.x1, y=coords.x2),
            shape=9, col="blue", size=2, alpha=1) +
  theme_bw()
```



On peut aussi afficher les points avec une taille proportionnelle au nombre de décès :

```
js_fond +
  geom_point(data=data.frame(deces_df), aes(x=coords.x1, y=coords.x2, size=Count),
            col="red", alpha=0.4) +
  geom_point(data=data.frame(pompes_df), aes(x=coords.x1, y=coords.x2),
            shape=9, col="blue", size=2, alpha=1) +
  theme_bw()
```



Visualisation de la densité du nombre de décès

Une autre visualisation possible est d'ajouter une couche de type "courbes de niveau" représentant la densité des cas décès. Cependant, le data frame comprend une seule ligne par localisation géographique et présente le cumul du nombre de décès pour chaque localisation. Pour que la densité de décès soit calculée correctement, il faut "éclater" les données de sorte qu'il y ait une ligne par décès. On peut utiliser la librairie `data.table` :

```
library(data.table)

deces_df_ex <- as.data.table(deces_df)
deces_df_ex <- deces_df_ex[rep(seq(1, nrow(deces_df_ex)), deces_df_ex$Count)]

# on supprime la colonne "Count" du nombre de décès
deces_df_ex$Count <- NULL

# on convertit le data.table en data.frame avec coordonnées
deces_df_ex <- as.data.frame(deces_df_ex)
coordinates(deces_df_ex) <- ~coords.x1+coords.x2
```


Maintenant, superposons sur le fond de carte la densité de décès (à noter ici que l'unité spatiale n'est pas une unité de surface, est le carré du degré de latitude/longitude) ainsi que la position des pompes :

```
js_fond +
  #geom_point(data=data.frame(deces_df), aes(x=coords.x1, y=coords.x2),
  #          col="red", alpha=0.3, size=1) +
  geom_density2d(data=data.frame(deces_df_ex),
                 aes(x=coords.x1, y=coords.x2), size = 0.3, col="gray") +
  stat_density2d(data = data.frame(deces_df_ex),
                 aes(x=coords.x1, y=coords.x2, fill=..level.., alpha=..level..),
```

```

size = 0.01, bins = 16, geom = "polygon") +
scale_fill_gradient(low = "yellow", high = "red", guide = FALSE) +
scale_alpha(range = c(0, 0.4), guide = FALSE) +
geom_point(data=data.frame(pompes_df), aes(x=coords.x1, y=coords.x2),
          shape=9, col="blue", size=2, alpha=0.8) +
theme_bw()

```



On remarque que le maximum de densité des décès coïncide avec la localisation d'une pompe en particulier, celle de Broad Street (le nom de la rue ne figure pas sur la tuile fournie par **Stamen**, mais se retrouve facilement sur la carte d'origine de Snow). Cette pompe semble donc être le point d'origine de l'épidémie de choléra.

Approche de statistique spatiale

Pour aller un peu plus loin, nous pouvons chercher à déterminer s'il y a une relation statistique entre les localisations des décès et celles des pompes. Nous allons faire l'approximation (grossière) que la localisation des décès et des pompes est un processus ponctuel ("point process" en anglais) spatialisé. L'analyse de ce type de processus est possible sous R grâce à la librairie **spatstat**.

Nous allons tout d'abord créer un nouveau dataframe qui combinera les deux jeux de données (décès et pompes) afin de se donner la possibilité d'analyser les deux ensemble. On obtiendra ainsi un objet de type "multitype marked point pattern" dans le quel chaque point est caractérisé par ses coordonnées sur la surface et par son type (cas de décès, ou pompe).

```

library(spatstat)

# ajouter une étiquette identifiant les décès par "d" et les pompes par "p"
deces_df$Id <- as.factor("d")
pompes_df$Id <- as.factor("p")

```



```
# fusionner les 2 dataframes
snow_df <- rbind(deces_df_ex, pompes_df)

summary(snow_df)
```

```
## Object of class SpatialPointsDataFrame
## Coordinates:
##           min           max
## coords.x1 -0.1400738 -0.1316299
## coords.x2 51.5100193 51.5158345
## Is projected: NA
## proj4string : [NA]
## Number of points: 497
## Data attributes:
##   Id
##   d:489
##   p: 8
```

Nous obtenons un objet de classe “SpatialPointsDataFrame”, qui doit maintenant être converti en “planar point pattern” pour être utilisé par la librairie SpatStat :

```
# définir la fenêtre correspondant à notre carte
win <- owin(c(bbox[1], bbox[3]), c(bbox[2], bbox[4]))

# convertir les coordonnées des décès en "planar point pattern"
snow_pp <- ppp(coordinates(snow_df)[,1], coordinates(snow_df)[,2], window = win, marks = snow_df$Id)

## Warning: data contain duplicated points


summary(snow_pp)
```

```
## Marked planar point pattern: 497 points
## Average intensity 4829932 points per square unit
##
## *Pattern contains duplicated points*
##
## Coordinates are given to 6 decimal places
##
## Multitype:
##   frequency proportion intensity
## d         489 0.98390340 4752187.00
## p          8 0.01609658  77745.38
##
## Window: rectangle = [-0.1433, -0.1286] x [51.5094, 51.5164] units
## Window area = 0.0001029 square units
```

Nous avons maintenant un objet analysable par `spatstat`. Ce que je propose de réaliser, c’est de faire une découpage de la carte en zones “d’influence” liées aux pompes. Une des manières les plus simples est d’utiliser la tessellation de Dirichlet/Voronoi, qui divise le plan en “tessels” (ou cellules) de sorte que pour chaque pompe (“germe”) le tessell associé est l’ensemble des points du plan qui sont plus proches de cette pompe que de toute autre pompe. Ainsi, si la pompe située broad Street est associée aux décès dus au choléra, l’essentiel de la densité des décès devrait se situer dans le tessell associé à cette pompe sur le graphique.

```
# division du plan en tessels associés aux pompes
tessels <- dirichlet(split(snow_pp)$p)
```

```
# graphique superposant la densité du nombre de décès, la position des pompes, et les tessels :
## densité des décès
plot(density(split(snow_pp)$d, sigma=2.5e-04), col=colorRampPalette(c("white","yellow","red")),
     main="", show.all=F)
## position des pompes
plot(split(snow_pp)$p, add=T, cols="blue", pch=9)
## ajout des tessels
plot(tessels, add=T)
```




A noter que pour cette première visualisation, les fonctions graphiques utilisent la librairie graphique de base de R (fonction `plot`) qui ne permet pas de visualiser la carte. On remarque toutefois que comme on l'attendait, la densité des décès semble concentrée autour de la pompe de Broad Street, et au sein du tessel associé.

La librairie `Spatstat` permet de tester l'association du nombre de décès avec les tessels selon un test du χ^2 : ce test compare le nombre de décès observés au sein d'un tessel avec le nombre attendu si le processus était aléatoire et indépendant du tessel considéré.

```
# estimation par Khi2 de la répartition aléatoire ou non du nombre de décès dans les tessels
quadr.test <- quadrat.test(split(snow_pp)$d, tess=tessels)

# graph superposant la densité du nombre de décès, la position des pompes, et les tessels :
# densité des décès
plot(density(split(snow_pp)$d, sigma=2.5e-04), col=colorRampPalette(c("white","yellow","red")),
     main="", show.all=F)
# position des pompes
plot(split(snow_pp)$p, add=T, cols="blue", pch=9)
# tessels + résultats du test de khi2 (nb de cas observés, nb de cas théorique, résidus)
plot(quadr.test, add=T)
```



Sur le graphique ci-dessus, au sein de chaque tessell nous avons les nombres de décès observés (en haut à gauche) et attendus (en haut à droite) ainsi que les résidus (en bas). Le test est significatif, et vaut 1028.08 ($P = 2.06 \times 10^{-217}$, $d.f. = 7$). Les valeurs négatives ou positives de résidus indiquent un nombre de décès plus faible ou plus fort qu'attendu, respectivement. Nous notons ainsi que la valeur de résidus la plus élevée (-27.17) correspond au tessell associé à la pompe de Broad Street.

Pour finir, essayons de transférer ces résultats pour une visualisation plus jolie sur le fond de carte avec ggplot2.

```
library(maptools)

# Convertir des tessels en polygones spatiaux
tessels_sppol <- as(tessels, "SpatialPolygons")
# Définir le système de projection
proj4string(tessels_sppol) <- CRS("+proj=longlat +datum=WGS84")
# Convertir les polygones en data frame pour ggplot2
tessels_df <- fortify(tessels_sppol)

# Graphique final
js_fond +
  #geom_point(data=data.frame(deces_df), aes(x=coords.x1, y=coords.x2),
  #          col="red", alpha=0.3, size=1) +
  geom_density2d(data=data.frame(deces_df_ex),
                 aes(x=coords.x1, y=coords.x2), size = 0.3, col="gray") +
  stat_density2d(data = data.frame(deces_df_ex),
                 aes(x=coords.x1, y=coords.x2, fill=..level.., alpha=..level..),
                 size = 0.01, bins = 16, geom = "polygon") +
  scale_fill_gradient(low = "yellow", high = "red", guide = FALSE) +
  scale_alpha(range = c(0, 0.4), guide = FALSE) +
  geom_point(data=data.frame(pompes_df),
             aes(x=coords.x1, y=coords.x2), shape=9, col="blue", size=2, alpha=0.8) +
  # ajout des tessels
  geom_polygon(data=tessels_df,
              aes(x = long, y = lat, group = group), color = "blue", fill = NA, size=0.5) +
  # ajout des résidus issus du test du chi2
  geom_label(data=data.frame(pompes_df),
            aes(x=coords.x1, y=coords.x2, label = round(quadr.test$residuals, 2),
              vjust = c(-0.5, 1.5, rep(-0.5, 6))), size=4, colour="blue", alpha=0.5) +
  theme_bw()
```

